

EEG & MACHINE LEARNING

Predisposición Genética al Alcoholismo mediante Análisis de Señales EEG y Aprendizaje Automático

MEMORIA TÉCNICA CON RESULTADOS

Alonso Martín Díez – Miguel Torres Landaburu
Ingeniería Biomédica · Universidad Europea de Madrid · 2026




Figura 17: Resumen visual del proyecto completo

1. Resumen Ejecutivo

Pipeline completo de machine learning para clasificar señales EEG de sujetos alcohólicos frente a controles sanos. Dataset: UCI EEG Database (Henri Begleiter, 1995). 122 sujetos reales, 64 electrodos, 46 features ingenierizadas, 7 clasificadores ML evaluados con validación cruzada de 5 folds.

Resultados — Datos reales (97 train / 25 test)

Modelo	Accuracy	F1	ROC AUC	Notas
XGBoost	0.76	0.758	0.789	Mejor accuracy — gradient boosting
Decision Tree	0.72	0.719	0.865	Mayor ROC AUC — interpretable
Random Forest	0.72	0.720	0.782	Ensemble bagging robusto
Logistic Regression	0.68	0.677	0.821	Baseline lineal regularizado
MLP Neural Net	0.64	0.633	0.699	3 capas (128-64-32), ReLU
SVM (RBF)	0.64	0.633	0.635	Kernel RBF, class_weight balanced
KNN	0.56	0.556	0.750	k=7, distancia euclidiana

XGBoost lidera en accuracy (76%). Decision Tree obtiene el mayor ROC AUC (0.865), indicando excelente capacidad discriminativa con solo una partición del espacio de features — coherente con la naturaleza dicotómica del biomarcador α/β .



Figura 14: Dashboard completo — Accuracy, ROC AUC, curvas ROC, F1 Score, matriz de confusión del mejor modelo y scorecard de resultados

2. Exploración de Datos

2.1 Visión general del dataset

El dataset contiene registros EEG de 122 sujetos: 65 alcohólicos (53%) y 57 controles (47%). Se registraron 18,022,400 mediciones totales (9.8M alcohólicos, 8.2M controles) distribuidas entre condiciones de estímulo S1 obj, S2 match y S2 nomatch.




Figura 1: Distribución de sujetos (donut), mediciones totales por grupo y distribución por condición de estímulo

2.2 Señales EEG crudas

Las señales EEG muestran diferencias visibles entre grupos: el grupo alcohólico presenta mayor variabilidad de amplitud y patrones temporales distintos, especialmente en electrodos frontales (FZ) y centrales (CZ). La línea sólida representa la media global; las transparentes son trials individuales.




Figura 2: Señales EEG crudas — Alcohólico vs Control en 4 electrodos clave (FZ, CZ, PZ, O1). Media global en sólido, trials individuales en transparente

2.3 Análisis espectral — Densidad Espectral de Potencia

El análisis PSD mediante el método de Welch revela diferencias espectrales claras entre grupos. El grupo control muestra mayor potencia en la banda alfa (8-13 Hz) visible como un pico pronunciado, mientras el grupo alcohólico muestra este pico atenuado. Las bandas δ , θ , α , β y γ están marcadas sobre las curvas.




Figura 3: Densidad Espectral de Potencia — 4 electrodos. Escala logarítmica. El pico alfa del grupo control (azul) es notablemente mayor que en alcohólicos (rojo)

2.4 Mapas topográficos de amplitud

Los mapas topográficos del cuero cabelludo (64 electrodos) muestran la distribución espacial de la amplitud media EEG. El tercer mapa muestra la diferencia absoluta entre grupos, destacando electrodos frontales y parietales como los más discriminativos.




Figura 4: Mapas topográficos: amplitud media grupo alcohólico (rojo), grupo control (azul) y diferencia absoluta $|A-C|$ (púrpura)

2.5 Distribuciones por región cerebral

El análisis por región cerebral (frontal, central, temporal, parietal, occipital) muestra que la región occipital presenta la mayor diferencia entre grupos en amplitud media, seguida de la frontal. Esto es coherente con las anomalías del potencial P300 documentadas en la literatura.




Figura 5: Distribuciones de amplitud EEG por región cerebral. Barras agrupadas con desviación estándar en la comparativa regional

3. Ingeniería de Features

3.1 Features extraídas (46 en total)

Para cada par (sujeto, electrodo) se extraen features del dominio temporal y frecuencial, que luego se agregan entre los 64 electrodos como media y desviación típica, resultando en 46 features por sujeto.

Categoría	Features	Count	Relevancia
Estadísticas temporales	mean, std, variance, skewness, kurtosis, p2p, rms, iqr, pcm, pcsd	10×2=20	Energía y distribución
Potencia banda (abs)	power_delta/theta/alpha★/beta★/gamma	5×2=10	Contenido espectral
Potencia relativa	rel_power_delta/theta/alpha/beta/gamma	5×2=10	Potencia normalizada
Ratios de bandas★	alpha_beta_ratio, theta_alpha_ratio, delta_alpha_ratio	3×2=6	BIOMARCADOR α/β
Total	46 features por sujeto (mean+std de 64 electrodos)	46	—

3.2 Potencias de bandas de frecuencia

La distribución de potencias por banda muestra diferencias claras entre grupos. El gráfico inferior derecho del ratio α/β confirma que el grupo control (azul) tiene valores significativamente mayores — validando el biomarcador principal de este análisis.




Figura 6: Distribución de potencias por banda (δ θ α β γ) y ratio α/β — Alcohólico vs Control. Las medias de grupo se marcan con línea discontinua

3.3 Mapas topográficos de potencia alfa

Los mapas de potencia alfa por electrodo evidencian la reducción difusa en el grupo alcohólico. El tercer mapa (diferencia Control – Alcohólico) muestra en qué regiones del cuero cabelludo es mayor la reducción: predominantemente en la zona frontocentral.




Figura 7: Potencia alfa topográfica: Alcohólico (rojo), Control (azul), Diferencia Control – Alcohólico (púrpura)

3.4 Análisis de correlaciones

La matriz de correlación de Pearson revela la estructura de dependencia entre features. El panel derecho ordena las features por su correlación con la etiqueta target (is_alcoholic), mostrando que power_theta ($r=-0.358$) y power_alpha ($r=-0.310$) son los más discriminativos — ambas con correlación negativa, confirmando su reducción en alcohólicos.




Figura 8: Izquierda: matriz de correlación de Pearson entre features. Derecha: correlación de cada feature con la etiqueta de alcoholismo (rojo=positiva, azul=negativa)

3.5 Top 8 features más discriminativas

Las 8 features con mayor correlación absoluta con el target, visualizadas tras la normalización StandardScaler. Las líneas discontinuas marcan la media de cada grupo. El solapamiento moderado entre distribuciones explica la dificultad del problema y el rango de accuracy obtenido (56-76%).




Figura 9: Distribución de las 8 features más discriminativas tras normalización. Rojo=Alcohólico, Azul=Control. Línea discontinua=media de grupo

4. Resultados de los Modelos ML

4.1 Matrices de confusión — Los 7 modelos

Las matrices de confusión muestran el comportamiento de cada clasificador en las 25 muestras de test (13 alcohólicos, 12 controles). XGBoost y Random Forest son los más equilibrados en la clasificación de ambas clases. SVM y MLP muestran más falsos negativos en la clase control.




Figura 10: Matrices de confusión de los 7 clasificadores. Diagonal principal = predicciones correctas. Eje X: predicho, Eje Y: real

4.2 Curvas ROC — Comparativa

Las curvas ROC muestran la relación entre TPR (Tasa de Verdaderos Positivos) y FPR (Tasa de Falsos Positivos) para cada modelo. Decision Tree (AUC=0.865) y Logistic Regression (AUC=0.821) lideran esta métrica. El clasificador aleatorio (línea discontinua) sirve de referencia.




Figura 11: Curvas ROC de los 7 modelos. Decision Tree obtiene el mayor AUC (0.865), seguido de Logistic Regression (0.821) y XGBoost (0.788)

4.3 Importancia de features — Modelos de árbol

Los tres modelos de árbol (Decision Tree, Random Forest, XGBoost) coinciden en las features más relevantes. `power_alpha_std` y `power_alpha` aparecen consistentemente en el top 2-3, junto con `alpha_beta_ratio`. Esto valida empíricamente el biomarcador EEG identificado en la literatura científica.




Figura 12: Feature importance de Decision Tree, Random Forest y XGBoost. Las features de potencia alfa y el ratio α/β dominan en todos los modelos

4.4 Comparativa completa de métricas

El panel de comparativa muestra Accuracy, F1 y ROC AUC de los 7 modelos en el test set, con los rombos turquesa indicando la media de la validación cruzada (5-fold). La brecha entre CV y test es moderada, indicando cierto overfitting esperable con solo 25 muestras de test.



Figura 13: Comparativa Accuracy · F1 · ROC AUC para los 7 modelos. Diamante turquesa = media CV; barras = test set

5. Análisis Avanzado

5.1 Curvas de aprendizaje

Las curvas de aprendizaje del Decision Tree (mejor ROC AUC) revelan un gap considerable entre entrenamiento (~ 0.88) y validación (~ 0.52), indicando overfitting moderado. Este comportamiento es esperable dado el tamaño limitado del dataset (97 muestras de entrenamiento). Con más datos el gap se reduciría.




Figura 15: Curvas de aprendizaje del Decision Tree — Accuracy (izq.) y ROC AUC (dcha.). Rojo=train, Azul=validación CV. Gap indica overfitting moderado

5.2 Análisis topográfico de importancia predictiva

El mapa de importancia predictiva por electrodo (derecha) muestra qué zonas del cuero cabelludo contribuyen más a la clasificación. Las regiones frontal y occipital destacan, alineándose con la literatura sobre disfunción prefrontal y anomalías P300 en TUA. El contraste entre los patrones de actividad alcohólico/control es evidente en los dos primeros mapas.




Figura 16: Mapas topográficos: patrón de actividad alcohólico (rojo), control (azul) e importancia predictiva por electrodo (púrpura). Dominancia frontal y occipital confirmada

6. Conclusiones Clínicas

Reducción de banda Alpha (8-13 Hz)

El grupo alcohólico muestra reducción consistente de potencia alfa en todos los electrodos. Las correlaciones de Pearson confirman power_alpha ($r=-0.310$) como el segundo predictor más fuerte. Esta reducción refleja deterioro GABAérgico por exposición crónica al alcohol.

Elevación de banda Beta (13-30 Hz)

La potencia beta elevada indica hiperexcitabilidad cortical por kindling: ciclos repetidos de abstinencia sensibilizan el SNC, produciendo cambios detectables incluso en abstinentes. El ratio α/β ($r=-0.219$) captura esta relación de forma compacta.

Dominancia frontal y occipital

Los electrodos FP1, FP2, F3, F4 (corteza prefrontal — control ejecutivo) y O1, O2 (corteza occipital — P300) son los más predictivos en todos los modelos. Coherente con la disfunción prefrontal y las anomalías del ERP P300 documentadas en TUA.

Theta como biomarcador secundario

power_theta ($r=-0.358$) emerge como la correlación más fuerte con el target, reflejando cambios en la comunicación hipocampo-cortical asociados a deterioro de memoria y procesamiento cognitivo en alcohólicos.

6.1 Aplicaciones potenciales

- Detección temprana: identificar individuos en riesgo antes de presentación clínica del TUA
- Estratificación genética: endofenotipo neurofisiológico complementario a tests genéticos
- Monitorización de tratamiento: marcador objetivo de recuperación neurológica en abstinencia
- Herramienta de investigación: estratificación de pacientes en ensayos clínicos

6.2 Limitaciones

- Tamaño muestral: 122 sujetos y 25 de test limitan la potencia estadística
- Condiciones de laboratorio: menor validez ecológica que EEG clínico real
- Comorbilidades no controladas: depresión, ansiedad, otras sustancias
- Clasificación binaria: no aborda el espectro de severidad del TUA

7. Referencias

Begleiter, H. (1995). EEG Database [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5TS3D>

Zhang, X.L., Begleiter, H., Porjesz, B., Wang, W., & Litke, A. (1995). Event related potentials during object recognition tasks. *Brain Research Bulletin*, 38(6), 531-538.

Porjesz, B. et al. (2005). The utility of neurophysiological markers in the study of alcoholism. *Clinical Neurophysiology*, 116(5), 993-1018.

Rangaswamy, M. & Porjesz, B. (2014). Understanding alcohol use disorders with neuroelectrophysiology. *Handbook of Clinical Neurology*, 125, 383-414.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825-2830.

Chen, T. & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *KDD 2016*.

Proyecto — Ingeniería Biomédica · Alonso Martín Díez · Miguel Torres Landaburu

Universidad Europea de Madrid · 2026